

Modelos para Inferência em Linguagem Natural que entendem a Língua Portuguesa

Giovani Tavares

Abril de 2023

1 Introdução

1.1 Processamento e Inferência de Linguagem Natural

O Processamento de Linguagem Natural (*NLP - Natural Language Processing*) é um ramo da Ciência da Computação que visa à extração de conhecimento do abundante volume de textos disseminados digitalmente de maneira nativa ou posteriormente digitalizados. A automatização dessa tarefa com a garantia de acurácia e eficiência à semelhança de como a fazem os seres humanos é o objetivo principal desse tipo de processamento (Chowdhary 2020) [1].

Essa área é subdividida em tarefas que se referem aos diferentes objetivos que sistemas que processam linguagens naturais possuem. A Inferência em Linguagem Natural (*NLI- Natural Language Inference*) é uma tarefa de NLP implementada por sistemas que determinam a relação lógica entre dois pares de sentenças P (premissa) e H (hipótese). A saída dessa determinação informa se a premissa implica, contradiz ou possui relação neutra com a hipótese (Salvatore, 2020) [2].

A criação de sistemas de NLI tem duas abordagens principais, sendo elas a simbólica e a baseada em aprendizado de máquina. A primeira usa a transformação do par formado pela premissa e hipótese em uma linguagem simbólica formal. O resultado dessa transformação é então passado por um sistema capaz de gerar as saídas citadas a partir de representações formais dos textos de entrada. Já o aprendizado de máquina trata a Inferência em Linguagem Natural como um problema de classificação dos mesmos pares de sentenças, mas transformados em vetores de covariáveis que representam numericamente as características dos textos. Esses vetores são as entradas de modelos de aprendizado de máquina que realizam a classificação ao gerar as referidas saídas (Salvatore, 2020). [2].

2 Motivação

O crescimento da quantidade de dados e textos disponíveis na *internet* possibilitou a criação de conjuntos de dados (*datasets*) com esses textos por pesquisadores

em NLP e entusiastas. Entre esses *datasets* há aqueles focados na tarefa de NLI que se tornaram *benchmarks* para os estudiosos da área. A criação de sistemas complexos, acurados e eficazes focados nessa tarefa foi por sua vez possibilitada por esses conjuntos de dados, sendo a abordagem de aprendizado de máquina a mais implementada por eles na atualidade.

Os *datasets* mais famosos e completos para a referida tarefa são escritos em língua inglesa, sendo eles o *Stanford Natural Language Inference Corpus* (SNLI) e o *Multigenre NLI Corpus* (MNLI). Esse fato alinhado à maneira que os modelos de aprendizado de máquina funcionam resulta em algumas consequências para o uso desses modelos e *benchmarks* com a Língua Portuguesa. Uma delas é a inviabilidade de utilizar boa parte desses modelos com essa língua sem nenhuma adaptação, uma vez que os modelos estatísticos, em geral, possuem baixo desempenho com entradas muito diferentes daquelas com as quais foram treinados. Um outro efeito é a baixa quantidade de informação que *benchmarks* disponíveis para tais modelos possuem quando se buscam modelos eficazes e acurados para o português, já que a maioria dos resultados apresentados são para testes feitos com *datasets* em inglês.

Desse modo, dois problemas diferentes e associados podem ser identificados: a disponibilização pública de modelos de NLI compatíveis com a Língua Portuguesa e a criação de *benchmarks* para esses modelos.

3 Objetivos

Tendo em vista os problemas anteriormente apresentados, o presente Trabalho de Conclusão de Curso (TCC) tem como objetivo principal a disponibilização de modelos de Inferência em Linguagem Natural compatíveis com a Língua Portuguesa em plataformas de acesso público como o *Hugging Face* [3]. Além disso, visa-se à realização de uma comparação sistemática do desempenho desses diferentes modelos de maneira a relacionar suas propriedades com aquelas dos *datasets*.

3.1 *Datasets* de NLI a serem utilizados para treinar os modelos

Os seguintes conjuntos de dados públicos serão utilizados no treinamento dos modelos de NLI para a Língua Portuguesa:

- **Avaliação de Similaridade Semântica e Inferência textual (ASSIN):** possui anotações de relacionamento semântico entre sentenças e aquelas ligadas a NLI. Foi utilizado na Conferência Internacional de Processamento Computacional da Língua Portuguesa de 2016 [4].
- ***Sentences Involving Compositional Knowledge - BR* (SICK-BR):** possui anotações de relacionamento semântico e de inferência entre sentenças para os dados traduzidos do inglês para o português extraídos do SICK original [5].

- **Avaliação de Similaridade Semântica e Inferência textual 2 (ASSIN2):**

é uma extensão do SICK-BR com mais exemplos. Esses exemplos foram criados a partir da modificação de dados do SICK-BR, substituindo palavras por seus sinônimos, por exemplo. Seu tamanho é aproximadamente igual ao do SICK-BR, mas suas anotações não possuem casos de sentenças contraditórias. Dessa forma, a tarefa de NLI é tratada nele como um problema de classificação binária no qual sentenças podem ou não ser implicação uma da outra [6]. Esse *dataset* foi utilizado no Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana (STIL, na sigla em inglês) realizado em Salvador (BA) no ano de 2019 [8].

Além desses *datasets*, pesquisar outros *datasets* públicos viáveis para a tarefa de interesse em plataformas como o *Hugging Face* é parte do trabalho a ser desenvolvido. A análise da viabilidade do emprego de descrições de textos (*features*) contidas em *datasets* como parte das entradas dos modelos treinados também será realizada. A tradução para o português do *General Language Understanding Evaluation* (GLUE), PLUE [9], possui alguns desses *features* a serem avaliados.

3.2 Requisitos para o Atingimento dos Objetivos

3.2.1 Disponibilização de modelos de Inferência em Linguagem Natural compatíveis com a Língua Portuguesa

Os modelos principais a serem utilizados como meios de obtenção daqueles que realizam o NLI para o português são o *ptBert-Large*, *ptBert-Base* e o *mBert-Base*, sendo todos eles modelos de aprendizado de máquina baseados em redes neurais profundas. Eles são instâncias do *BERTimbau* [7], que é um modelo *BERT* treinado para a Língua Portuguesa Brasileira.

A técnica de *fine-tuning* será aplicada para a utilização dos modelos citados. Em linhas gerais, o *fine-tuning* é baseado na modificação parcial dos parâmetros que definem um modelo de aprendizado de máquina a fim de torná-los mais apropriados a determinada tarefa e/ou conjunto de dados. Uma vez que os modelos citados não foram treinados para a tarefa específica de NLI, essa técnica é apropriada para o objetivo em questão.

Além do treinamento dos modelos, para que a disponibilização desses modelos seja considerada concluída será necessário a sua documentação. Essa documentação inclui dados sobre as máquinas que realizaram os treinamentos, informações sobre algumas camadas das redes neurais, as razões das escolhas de alguns hiperparâmetros dentre outros aspectos a serem desenvolvidos ao longo do TCC.

3.2.2 Criação de *benchmarks* que permitam a avaliação conjunta e comparação desses modelos segundo diferentes métricas

Os *benchmarks* que serão desenvolvidos para os modelos de NLI treinados para o português conterão métricas comuns utilizadas na avaliação de modelos de

aprendizado de máquina, como acurácia, precisão, sensibilidade entre outras a serem definidas ao longo do TCC.

Além disso, a avaliação cruzada dos modelos será feita. Essa técnica será aplicada com o uso de conjuntos de testes para um modelo extraídos de *datasets* diferente daqueles utilizados em seu treinamento. Dessa forma, busca-se avaliar a capacidade de generalização dos modelos, ou seja, o quão acurados e eficientes eles são em realizar NLI para pares genéricos de sentenças escritas na Língua Portuguesa.

4 Principais Referências

A seguir, algumas referências a serem utilizadas no desenvolvimento do TCC.

- **Fialho, P., Coheur, L., & Quaresma, P.** (2020) - Benchmarking Natural Language Inference and Semantic Textual Similarity for Portuguese.
- **Salvatore, F.S** (2020) - Analyzing Natural Language Inference From a Rigorous Point Of View.
- **Devlin, J., Chang, M., Lee, K., Toutanova, K.** (2019) - BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.
- **Real, L., Rodrigues, A., Vieira e Silva, A., Albiero, B., Thalenberg, B., Guide, B., Silva, C., de Oliveira Lima, G., C. S. Câmara, I., Stanojevic, M., Souza, R. & de Paiva, V.** (2018) - SICK-BR: A Portuguese Corpus for Inference.
- **Real, L., Fonseca, E., & Oliveira, H.** (2020) - The ASSIN 2 shared task: a quick overview.
- **Fonseca, E., Santos, L., Criscuolo, M., & Aluísio, S.** (2015) - ASSIN: Avaliação de Similaridade Semântica e Inferência Textual.
- **Devlin, J., Chang, M., Lee, K., Toutanova, K.** (2019) - BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.

References

- [1] **Chowdhary, K.R** (2020) - Natural Language Processing. In: Fundamentals of Artificial Intelligence. Springer, New Delhi.
- [2] **Salvatore, F.S** (2020) - Analyzing Natural Language Inference From a Rigorous Point Of View
- [3] <<https://www.bbc.com/portuguese/geral-37658309>>
- [4] <<http://nilc.icmc.usp.br/assin/>>

- [5] **Real, L., Rodrigues, A., Silva, A., Albiero, B., Thalenber, B., Guide, B., Silva, C., Lima, G., Câmara, I., Stanojevic, M., Souza, R., & Paiva, V.** (2018) - SICK-BR: a Portuguese corpus for inference.
- [6] **Fialho, P., Coheur, L., & Quaresma, P.** (2020) - Benchmarking Natural Language Inference and Semantic Textual Similarity for Portuguese.
- [7] **Souza, F., Nogueira, R., & Lotufo, R.** (2020) - BERTimbau: Pretrained BERT Models for Brazilian Portuguese.
- [8] <<https://sites.google.com/view/assin2/>>
- [9] <<https://huggingface.co/datasets/dlb/plue>>
- [10] <<https://gluebenchmark.com/>>